

## **Titreşim Sönümlerici Burçlarda Tasarım Parametrelerinin Optimizasyonuna Yönelik FEM ve Makine Öğrenmesi Tabanlı Metodoloji**

**<sup>1</sup>M. Emre DARI**, Yamas Yaşa Makine Kalıp Oto Yedek Parça San. Tic. A.Ş

**<sup>2</sup>B.Kaan ZANBAK**, Yamas Yaşa Makine Kalıp Oto Yedek Parça San. Tic. A.Ş

**<sup>3</sup>Semih KOÇAK**, Yamas Yaşa Makine Kalıp Oto Yedek Parça San. Tic. A.Ş

<sup>1</sup>*emre.dari@yamas.com.tr*, <sup>2</sup>*berkcan.zambak@yamas.com.tr*, <sup>3</sup>*semih.kocak@yamas.com.tr*

### **ÖZET**

**Araç süspansiyon sistemlerinde kullanılan titreşim sönümleyici burçlar**, şasi ile süspansiyon parçaları arasındaki bağlantıyı sağlayan önemli elemanlardır. Bu burçların temel görevi, sürüsü sırasında oluşan titreşim ve gürültüyü azaltarak konforu artırmaktır. Bunun yanı sıra, sistem içerisinde meydana gelebilecek dengesizlikleri gidermek ve yük aktarımını optimize etmek amacıyla da özel olarak tasarlanmaktadır. Montaj konumlarına göre farklı yönlerde hareket edebilmeleri, burçların birden fazla doğrultuda farklı mekanik tepkiler göstermesini gereklili kılmaktadır. Bu nedenle eksenel ve radyal doğrultularda farklı direngenlik değerlerine sahip olmaları beklenmektedir.

Bu çalışma, iç boru, dış boru ve elastomer bileşenden oluşan silindirik burçların **eksenel ve radyal direngenlik özelliklerinin** makine öğrenmesi yöntemleri ile modellenmesini amaçlamaktadır. Çalışmanın ilk aşamasında, direngenliği etkileyen tasarım parametreleri belirlenmiştir. İç borunun uzunluğu, çapı ve bağlantı geometrileri sabit kabul edilmiş; kauçuk bileşenin yüksekliği, genişliği, sertliği ve ön sıkıştırma (kalibre) oranı ise değişken parametreler olarak tanımlanmıştır. Sonraki adımda, oluşturulan farklı tasarım varyantları üzerinde **sonlu elemanlar yöntemi (FEM)** kullanılarak yapısal analizler gerçekleştirilmiştir. Ön işleme işlemleri **MSC/Apex** yazılımı kullanılarak yapılmış, doğrusal olmayan analizler ise **MSC/Marc** programı aracılığıyla yürütülmüştür. Bu analizlerden elde edilen eksenel ve radyal direngenlik sonuçları, makine öğrenmesi modelinin eğitiminde veri seti olarak kullanılmıştır.

Makine öğrenmesi sürecinde **denetimli öğrenme temelli yapay sinir ağları** tercih edilmiş ve model performansı iteratif olarak iyileştirilmiştir. Farklı ağ mimarileri ve parametre ayarları denenmiş, hata oranı en düşük seviyeye indirilene kadar eğitim süreci devam ettirilmiştir. Böylece, burçların direngenlik özellikleri yalnızca analiz sonuçlarına dayalı değil, aynı zamanda makine öğrenmesi tabanlı tahmin mekanizmasıyla da elde edilebilmiştir.

Elde edilen bulgular, burç tasarım sürecinde deneyisel ve sayısal analizlere duyulan ihtiyacı azaltarak tasarım döngülerinin kısaltılabilmesini göstermektedir. Bununla birlikte, daha doğru tahminlerle tasarım optimizasyonu yapılmaktı ve prototip üretim maliyetlerinde tasarruf sağlanabilmektedir.

Sonuç olarak, bu çalışma otomotiv endüstrisinde **titreşim yalıtımına yönelik burç tasarımlarının daha etkin, hızlı ve güvenilir bir şekilde gerçekleştirilmesine katkı sunmaktadır**. Makine öğrenmesi destekli yaklaşımın, klasik sonlu elemanlar analizleri

ile birlikte kullanıldığında, mühendislik tasarım süreçlerinde önemli avantajlar sağlayabileceği ortaya konulmuştur.

**Anahtar Kelimeler:** Titreşim sönümleyici burç, Sonlu elemanlar yöntemi, Makine öğrenmesi, Direngenlik, Yapay sinir ağları

## 1. GİRİŞ

Konvansiyonel titreşim sönümleyici burçlar, süspansiyon sistemlerinin konfor ve dayanım performansını belirleyen temel bileşenler arasında yer almaktadır. Bu burçlar, rıjıt iç ve dış metal boruların arasında konumlandırılmış viskoelastik kauçuk malzemeden oluşan çok bileşenli bir yapıya sahiptir. Kauçuk malzeme, titreşim etkisiyle maruz kaldığı tekrarlı yükler altında gösterdiği deformasyon davranışları ve iç sürtünme kaynaklı enerji kayipları sayesinde titreşim enerjisini ısı enerjisine dönüştürerek etkin bir sönümleme mekanizması oluşturur. Bu özellik, süspansiyon sisteminin çalışma stabilitesini artırmakta, metal bileşenlerin kontrollü hareketine imkân sağlamaktada aynı zamanda bağlı aktarma organlarının servis ömrüne olumlu yönde katkı sunmaktadır.

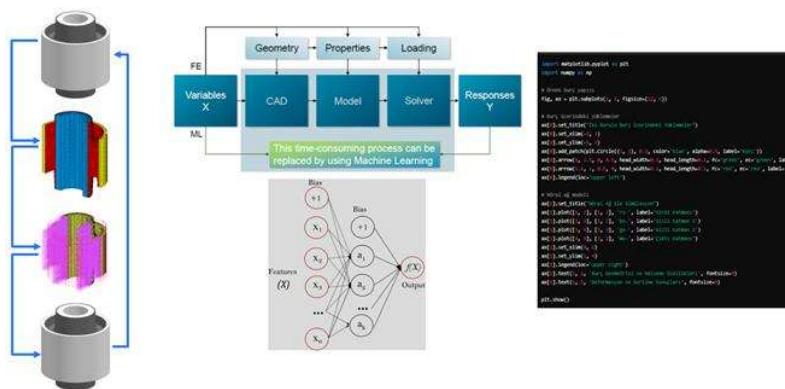
Titreşim sönümleyici bir burcun tasarımda, sınırlı yerleşim hacmi içerisinde beklenen statik ve dinamik direngenlik gereksinimlerinin karşılanması ve hedeflenen عمر performansının sağlanması temel tasarım kriterleridir. Bu gereksinimlerin doğrulanması aşamasında, burcun karmaşık malzeme davranışları ve geometrik özelliklerinin ayrıntılı olarak incelenmesi için sonlu elemanlar yöntemine başvurulmaktadır. Sonlu Elemanlar Analizi (SEA), burcu oluşturan tüm bileşenlerin etkileşimini sayısal olarak modelleyerek yükleme altındaki gerilme, deformasyon ve yer değiştirme dağılımlarının güvenilir bir şekilde tahmin edilmesine olanak sağlar. Böylece tasarım sürecinde ortaya çıkabilecek zayıf noktalar tespit edilebilmekte ve gerekli yapısal iyileştirmeler erken aşamada uygulanabilmektedir. SEA kullanımı, farklı malzeme seçenekleri ve tasarım varyasyonlarının klasik deneme-yanılma yaklaşımına kıyasla çok daha hızlı ve düşük maliyetli bir şekilde değerlendirilmesini mümkün kılarak ürün geliştirme döngüsünü önemli ölçüde kısaltmaktadır. Güncel tasarım ve doğrulama pratiklerinde ise bu yöntem, çeşitli optimizasyon teknikleriyle bir araya getirilerek daha gelişmiş bir mühendislik aracı haline gelmiştir. Özellikle kauçuk gibi doğrusal olmayan malzemelerin kullanıldığı titreşim sönümleyici burç uygulamalarında, makine öğrenmesi temelli optimizasyon yaklaşımının literatürde geleneksel tasarım-analiz döngüsünü belirgin biçimde iyileştirdiği ve mühendislik süreçlerinin verimliliğini artırdığı gösterilmektedir.

Bu kapsamda Töpel ve arkadaşları, yapmış olduğu çalışma ile şasi burçlarının tasarımını için yapay sinir ağları ve tasarım optimizasyonu tabanlı bir yöntem geliştirmiştir. İlk olarak, sonlu elemanlar yöntemi (SEA) kullanılarak bir model oluşturulmuş ve malzeme parametreleri optimize edilmiştir. Daha sonra, deney tasarım yöntemi ile çeşitli numuneler üretilip, geometrik model tanımları tasarlanmıştır. SEA simülasyonları ile veritabanı oluşturulup, yapay sinir ağının eğitimi için kullanılmıştır. Parçacık sürüsü optimizasyonu (PSO) kullanılarak tasarım parametreleri tersine çevrilmiştir. Sonuçlar, SEA simülasyonları ile doğrulanmıştır (Töpel, 2023).

Aydoğdu, Yüksek lisans tez çalışmasında, yapıların mekanik davranışını modellemek ve optimize etmek için yapay sinir ağları kullanan bir makine öğrenmesi modeli geliştirmiştir. Makine öğrenmesi modeli, sonlu elemanlar analizine dayanarak oluşturulmuştur. Model, yapıların optimizasyonu için gerekli olan amaç ve kısıt fonksiyonlarını belirlemeye kullanılmıştır. Veri setinin elde edilmesi, modelin eğitilmesi ve doğrulanması süreci gerçekleştirılmıştır. Eğitilen model, hem doğrusal hem de doğrusal

olmayan yapıların optimizasyon çalışmalarında genetik ve diferansiyel gelişim algoritmaları ile kullanılmıştır (Aydoğdu, 2023).

Kaya bu çalışmada, son yıllarda global optimum bulmak için kullanılan doğrusal olmayan algoritmalar arasında diferansiyel evrim (DE) algoritması öne çıkmaktadır. DE ve parçacık sürü optimizasyonu yöntemleri çeşitli bilim ve mühendislik uygulamalarında başarılı sonuçlar vermiştir. Bu çalışma, lastik burçlarının hedeflenen sertlik eğrilerini karşılamak için DE algoritmasını kullanarak şekil optimizasyonu önermektedir. Şekil optimizasyonu, DE algoritmasıyla gerçekleştirilmiş ve lastik burçlarının radyal yönlerdeki sertlik eğrileri sonlu elemanlar yöntemi ile elde edilmiştir (Kaya, 2014).

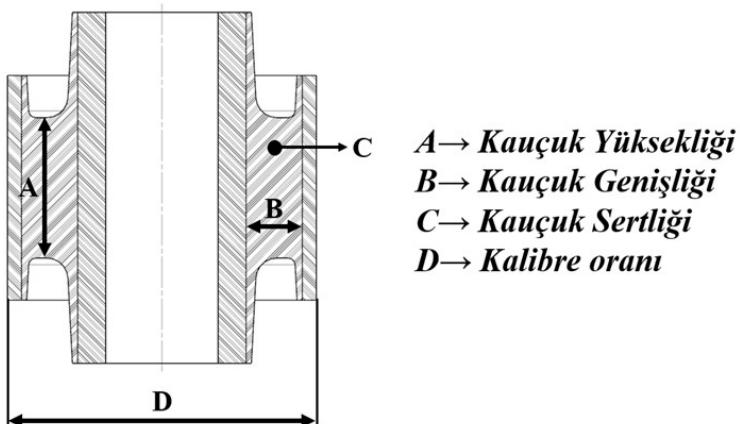


Şekil 1. Sonlu elemanlar ile tasarım doğrulama süreci ve makine öğrenimi sürecinin karşılaştırılması

Bu çalışmada, konvansiyonel titreşim söñümleyici burçların radyal ve eksenel yükler altındaki davranışını tahmin edebilmek amacıyla, sonlu elemanlar analizlerinden elde edilen çıktıların makine öğrenmesi modellerine aktarılmasıyla çalışan yeni bir hesaplama yaklaşımı geliştirilmiştir. Analiz süreçlerinde kauçuk eleman hiperelastik bir malzeme modeliyle tanımlanmış, iç ve dış metal bileşenler ise rijit kabul edilmiştir. Kauçuk malzemeye ait gerilim–gerinim ölçümleri mühendislik değerlerine dönüştürülerek uygun hiperelastik model parametreleri oluşturulmuştur.

Belirlenen farklı burç geometrileri ve sınır koşulları için gerçekleştirilen statik yapısal analizler sonucunda burçların statik direngenlik katsayıları elde edilmiş ve bu veriler makine öğrenimi tabanlı tahmin sisteme giriş olarak kullanılmıştır. Analiz sonuçlarının doğrulaması fizikal testler üzerinden yapılmış ve oluşturulan veri setinin hassasiyet düzeyi ortaya konmuştur. Modelde kullanılan temel tasarım değişkenleri; kauçuk yüksekliği, genişliği, malzeme sertliği ve çekme davranışının etkisini azaltan kalibre oranı olarak Şekil 2'deki gibi belirlenmiştir.

Geliştirilen makine öğrenimi modeli, burçların radyal ve eksenel yüklemeler altındaki davranışını yüksek doğrulukla ve klasik SEA analizlerine göre çok daha kısa sürede tahmin edebilmiştir. Şekil 1'de görüldüğü üzere geleneksel tasarım–mesh–sınır koşulu tanımlama döngüsünün her iterasyonda tekrar edilmesi gerekliliği ortadan kalkmış, optimum sonuçlara erişim önemli ölçüde hızlandırılmıştır.



Şekil 2. Statik direngenlik katsayısına etki eden tasarım parametreleri

## 2. MATERİYAL VE METOT

### 2.1 Makine Öğrenme Tabanlı Tasarım Optimizasyon Metodolojisi

Makine öğrenimi, yapay zekâ alanı içerisinde giderek önem kazanan ve geniş uygulama yelpazesi sunan bir araştırma alanıdır. Bu yaklaşım, klasik programlama yöntemlerinden farklı olarak, algoritmaların verilerden anlam çıkararak öğrenmesine ve ortaya çıkan örüntüler doğrultusunda kararlar vermesine olanak tanımaktadır. Makine öğrenimi teknikleri genel olarak denetimli öğrenme, denetimsiz öğrenme ve güçlendirmeli öğrenme olmak üzere üç temel sınıfta incelenmektedir.

Denetimli öğrenme yöntemleri, her örneğin doğru çıktı bilgisine sahip olduğu etiketli veri setleriyle çalışır ve bu nedenle sınıflandırma ile regresyon problemlerinde yaygın şekilde tercih edilir. Buna karşın, denetimsiz öğrenme teknikleri etiketlenmemiş veriler üzerinde çalışarak, veri içerisindeki doğal grupları, ilişkileri ve yapısal örüntüleri ortaya çıkarmayı amaçlar. Güçlendirmeli öğrenme ise bir ajanın belirli bir ortamda gerçekleştirdiği eylemler sonucunda aldığı ödül sinyallerine dayanarak en uygun davranış stratejisini geliştirmesini hedefler ve özellikle robotik ile oyun tabanlı uygulamalarda önemli bir kullanım alanı bulur.

Bu çalışma kapsamında, titreşim sönmeyici burçların seçilen tasarım değişkenlerine bağlı olarak radyal ve eksenel statik direngenlik değerlerinin tahmin edilmesi için denetimli öğrenme yaklaşımından yararlanılmıştır. Ayrıca, hedef direngenlik değerlerini sağlayabilecek optimum tasarım parametrelerinin belirlenmesinde de aynı yöntem kullanılarak tasarım sürecine karar destek sağlanmıştır.

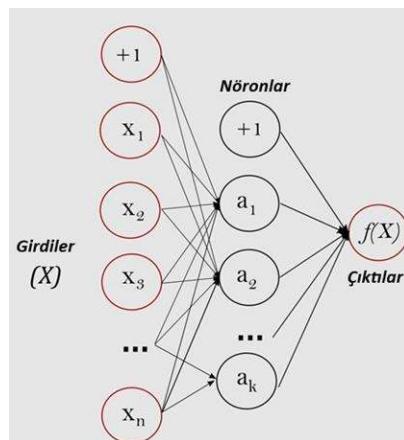
#### 2.1.1 Denetimli Öğrenme (Supervised Learning)

Denetimli öğrenme, çıktıları bilinen veri setleri kullanılarak modellerin eğitildiği bir makine öğrenmesi yaklaşımıdır. Bu yöntemde model, girdi ve çıktı çiftleri arasındaki ilişkiyi öğrenerek yeni örnekler için doğru tahminler üretmeye çalışır. Çalışma kapsamında, çeşitli denetimli öğrenme teknikleri değerlendirilmiş ve performans açısından en uygun yöntem olarak yapay sinir ağı algoritması tercih edilmiştir. Yapay sinir ağları, biyolojik sinir sisteminin işleyişini temel alan, veri içerisindeki karmaşık örüntüleri modelleme yeteneği yüksek olan hesaplama yapılarıdır.

Modelde kullanılan sinir ağı mimarisi Şekil 3'te gösterildiği üzere üç temel bileşenden oluşmaktadır.

- **Giriş Katmanı (Input Layer):** Veri setindeki özelliklerin modele aktarıldığı ilk katmandır. Her nöron bir giriş değişkenini temsil eder.
- **Gizli Katmanlar (Hidden Layers):** Giriş ve çıkış katmanları arasında yer alan bu katmanlar, veriyi işleyerek ilişkilerin soyutlanmasını sağlar ve öğrenme sürecinin esas bölümünü oluşturur.
- **Çıkış Katmanı (Output Layer):** Modelin tahmin değerlerini üreten son katmandır ve ilgili problem tipine uygun şekilde yapılandırılır.

Bu yapı sayesinde sinir ağı, tasarım değişkenleri ile burç direngenlik sonuçları arasındaki bağıntıları etkili bir şekilde öğrenebilmekte ve tahmin sürecinde yüksek doğruluk sağlayabilmektedir.



Şekil 3. Nöral ağ katman yapısı

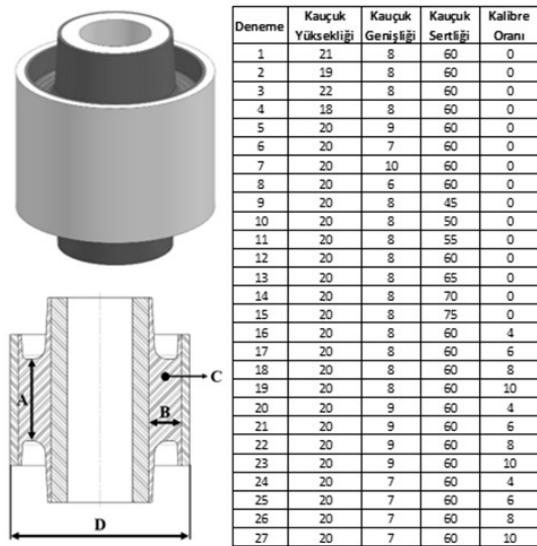
Giriş katmanı için belirlenen parametreler; kauçuk yüksekliği, genişliği, sertliği ve kalibre oranıdır. Çıkış katmanları ise radyal direngenlik veya eksenel direngenliktir. Sinir ağ tabanlı yapıda iki çıkış katmanı olamaz bu sebeple radyal ve eksenel için ayrı iki ağ kurulmuştur.

## 2.2 Tasarım Değişkenlerinin ve Varyasyonlarının Belirlenmesi ve Doğrulama Çalışmaları

Çalışmada belirlenen tasarım parametrelerine göre yaklaşık 30 tasarım varyantı oluşturulmuştur. Bu varyantlar, makine öğrenme yöntemine uygun olarak tasarlanmıştır. Parametreler arasında nominal ölçüler, kauçuk sertliği ve kalibre oranı yer almaktadır. Yazılımın öğrenme sürecinde, farklı ölçülerde, kauçuk sertliklerinde ve kalibre oranlarında varyantlar kullanılarak tasarımlar gerçekleştirilerek modeller oluşturulmuştur. Bütün parametrelerin öğrenilmesi adına tasarımlar gerçekleştirilmiştir.

Örneğin Tablo.1'de görüldüğü gibi, yazılımın öğrenmesi kauçuk yükseklik etkisi için diğer parametreler nominal olarak tutulmuş ve sadece kauçuk yüksekliği ölçüleri değiştirerek tasarımlar gerçekleştirilmiştir. Diğer yandan birden fazla parametrenin birbirine olan etkisini değerlendirebilmek adına belirlenen diğer tasarım parametreleri de aynı metot ile çıkarılarak sonuçların optimum düzeyde çıkarımı sağlaması amaçlanmıştır.

Tablo 1. Tasarım varyasyonları ve ilgili tasarım parametreleri



### 2.2.1 Burcun Kauçuk Malzemesinin Hiperelastik Malzeme Modeli

Doğal kauçuk, sıkıştırılamayan ve doğrusal olmayan elastik izotropik davranış gösteren hiperelastik bir malzeme olarak düşünülebilir (2). Kauçuk komponentlerin analizlerinde hiperelastik malzemedenki gerilim ve gerinim arasındaki ilişki, genellikle gerinim enerji fonksiyonu ile karakterize edilir. İki parametrelî Mooney-Rivlin fonksiyonu, bu çalışmada doğal kauçugun malzeme modelini belirlemek için seçilmiştir. (3, 4) Mooney-Rivlin modelinin sonsuz seri şeklindeki gösterimi (1) ve iki parametreleri Mooney-Rivlin gösterimini (2) denklemleri görülmektedir. Oluşturulan tasarım varyantlarının yapısal analizlerinde her kauçuk formülasyonu için belirlenen bu hiperelastik malzeme modelleri kullanılmıştır.

$$W(I_1, I_2) = \sum_{i,j=1}^{\infty} c_{ij}(I_1 - 3)^i (I_2 - 3)^j \quad (1)$$

$$W = c_{10}(I_1 - 3) + c_{01}(I_2 - 3) \quad (2)$$

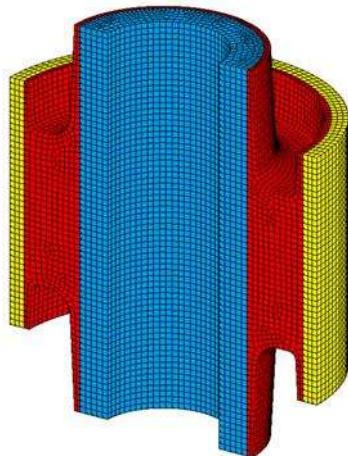
W: Gerilme enerjisinin yoğunluğu (birim hacim başına enerji),

C<sub>ij</sub>: Malzeme parametreleri (sabitler),

I<sub>1</sub> ve I<sub>2</sub> : Deformasyon tensörünün ilk ve ikinci değişmezleri (invaryantlar).

### 2.2.2 Ön İşleme Adımı Çalışması

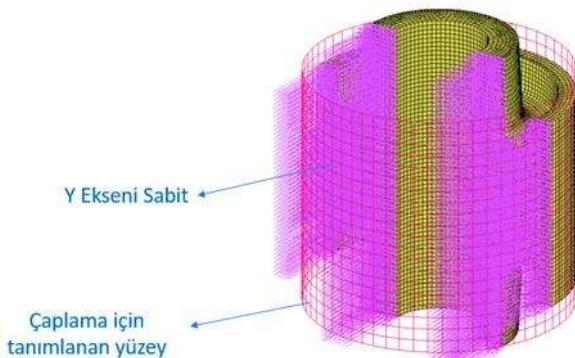
Oluşturulan tasarımların herbiri için mesh yapısı oluşturulmuştur. Her tasarım varyantı için oluşturulan ön işleme adımında yarı model kullanılarak ön işleme adımları gerçekleştirilmiştir. Tüm varyasyonlarda eleman tipi Hex8, mesh boyutu 0,75 mm olarak çalışılmıştır.



Şekil 4. Tasarım varyantlarına bağlı ön işleme modeli

### 2.2.3 Sınır Koşulları ve Yapısal Analizler

Burcun fiziksel test aşamasında önce ilgili üretim proseslerinde vulkanizasyon öncesi hazırlık için iç boru ve dış boruya yapıştırıcı uygulaması yapılmakta sonrasında ise vulkanizasyon işlemi gerçekleştirilmektedir. Bu nedenle burcun iç borusu ve dış borusu kauçuğa glue kontakt olarak tanımlanmıştır. Parçanın montaj koşulları dikkate alınarak; Şekil 5'teki gibi tanımlanan yüzey parçasının çalışma esnasında kauçugün çekme yönündeki zayıf davranışını elimine etmek dolayısıyla üzerindeki gerinim dağılımlarını azaltmak için ön sıkıştırma işlemi uygulamak için tanımlanmıştır. Yarım model çalışıldığından dolayı Y ekseni sabit tutulmuştur. Yapısal analizlerde her tasarım varyantı için ilgili yönlerde hareket tanımlaması yapılarak analizler koşturulmuş ve gerinim dağılımları ile birlikte kuvvet-deplasman eğrileri üzerinden statik direngenlik katsayıları hesaplanmıştır.



Şekil 5. Sonlu elamanlar yöntemiyle yapısal analizler için tanımlanan sınır koşulları

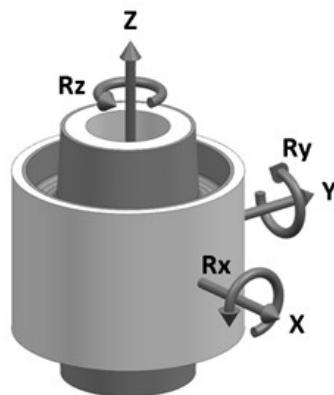
### 2.3 Statik Karakterizasyon Testleri

Kauçuk malzemelerin farklı uzama oranlarında farklı karakteristik eğrileri vardır. (Wang, 1998), (Legorju-jago ve Bathias, 2002). Bu nedenle, ürünlerin hangi yükleme koşullarında çalışacağını bilmek ve uygun şekilde test etmek gerekmektedir. Bu kapsamda her tasarım varyantına ait statik test parametreleri aynı test koşuluyla yapılarak kayıt altına alınmıştır.



Şekil 6. Zwick Roell test kurulumu

Ürünün statik testleri Zwick Roell test makinesinde gerçekleştirılmıştır. Şekil 6'da Zwick Roell test kurulumu gösterilmiştir. Test makinesi 30 kN ve 600 mm kapasitelidir. Statik testler Şekil 7'de gösterilen test yönlerinde Tablo 2'de belirtilen parametrelerde gerçekleştirilmiştir.



Şekil 7.  $\pm X$  ve  $\pm Y$  radyal yön,  $\pm Z$  eksenel yön,  $\pm Rx$  ve  $\pm Ry$  kardanik yön,  $\pm Rz$  torsiyonel yön

Tablo 2'de belirtilen şartlandırma çevrimleri, Mullins etkisini ortadan kaldırma amacıyla gerçekleştirilmiştir. Bu nedenle, kuvvet-yer değişim grafiği, uygulanan testin 4. Döngüsüne dayanmaktadır (Mullins ve Tobin, 1969).

Tablo 2. Statik test parametreleri

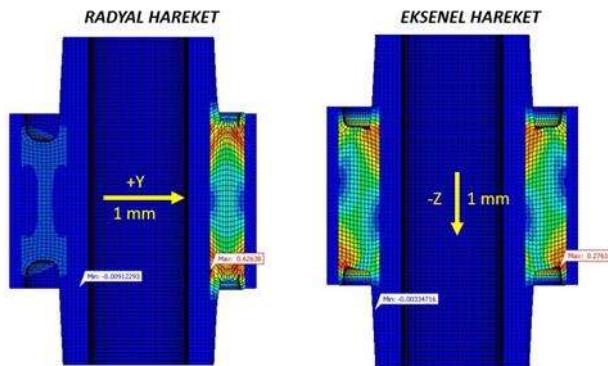
	Y (Radyal)	Z (Eksenel)
Ön Yük	100 N	100 N
Ön Şartlandırma Hızı	50 mm/dk	50 mm/dk
Ön Şartlandırma Yükü	$\pm 1$ mm	$\pm 1$ mm
Ön Şartlandırma Çevrimi	3	3
Gecikme	10 saniye	10 saniye
Test Hızı	10 mm/dk	10 mm/dk
Test Yükü	$\pm 1$ mm	$\pm 1$ mm

### 3. SONUÇLAR

Makine öğrenme metodolojisine göre programa verilerin entegre edilmesi için öncesinde parçaların yapısal analizleri ile birlikte fiziksel test sonuçları karşılaştırılarak doğrulanmıştır. Ardından tasarım değişkenlerine bağlı ilgili varyantların test verileri programa makine öğrenmesi için entegre edilmiştir.

#### 3.1 Yapısal Analiz Sonuçları

Oluşturulan sınır koşulları ile radyal yönde ( $\pm Y$ ) 1 mm deplasman verilerek analiz 3600 saniyede gerçekleştirılmıştır. Aynı şekilde eksenel yönde ( $+Z$ ) 1 mm deplasman verilerek analiz 3000 saniyede gerçekleştirılmıştır. Analiz sonuçları her bir tasarım varyantı için ayrı ayrı elde edilmiştir.

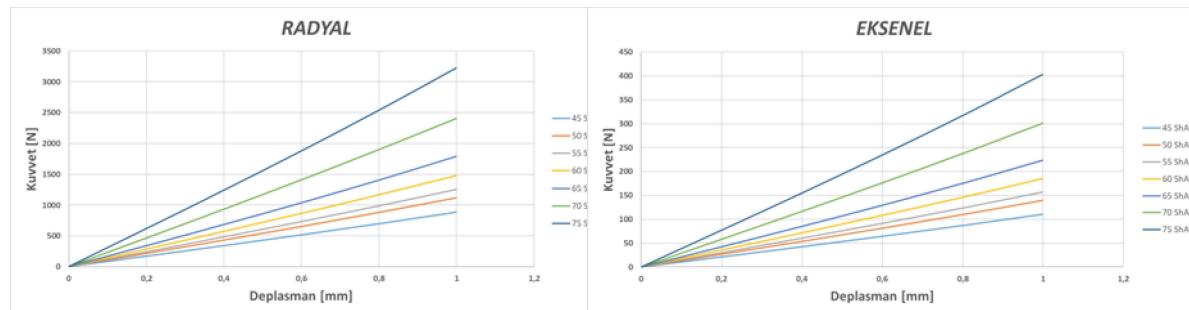


Şekil 8. Radyal ve eksenel yönde sonlu elemanlar yapısal analizleri

Tüm tasarım varyasyonları ve daha önceden elde edilen yapısal analiz sonuçları Şekil 9'da paylaşılmıştır. Elde edilen kuvvet-deplasman eğrilerinden statik direngenlik değerlerinin hesaplamaları gerçekleştirilerek makina öğrenme metoduna entegre edilecek şekilde listelenmiştir.

Kurgulanan tasarım modelleri için kauçuk sertliği haricinde her biri için ön işleme adımları uygulanarak analizler gerçekleştirılmıştır. Yapısal analizler sonucu kuvvet-deplasman eğrileri elde edilmiştir. Statik direngenlikler (K<sub>s</sub>), kuvvet-deplasman eğrilerinin doğrusal bölgeleri baz alınarak tüm varyantlar için hesaplanmıştır.

Elde edilen radyal ve eksenel yönlerdeki kuvvet deplasman eğrileri Şekil 9'da paylaşılmıştır.

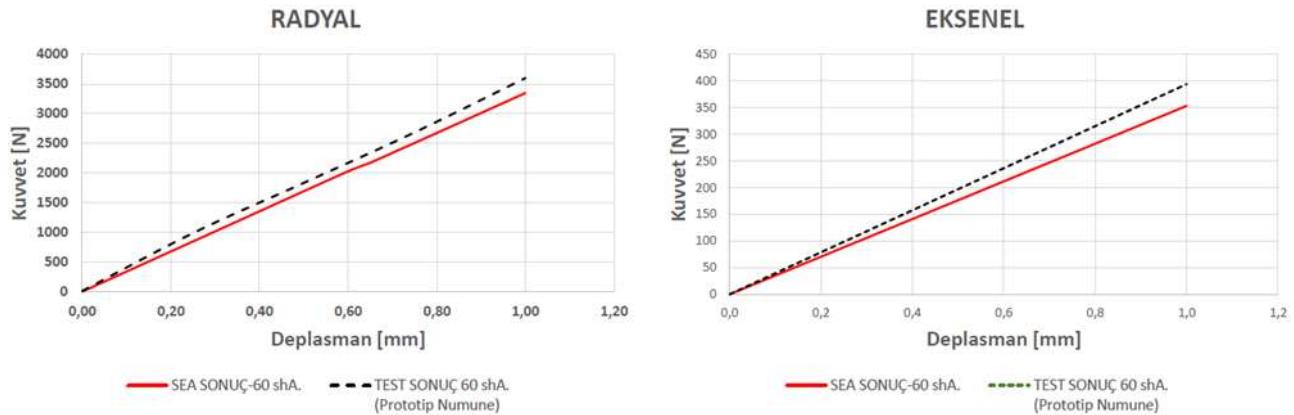


Şekil 9. Radyal ve eksenel yönlerdeki yapısal analiz kuvvet-deplasman eğrileri

#### 3.2. Fiziksel Test Sonuçları

Prototip kalıplardan üretimleri gerçekleştirilen tasarım varyantlarına ait parçaların fiziksel test sonuçları toplanmıştır. Fiziksel test sonuçları ve yapısal analiz sonuçlarının karşılaştırması yapılarak doğruluk oranları çıkartılmıştır. Tüm çalışmada aynı şekilde test ve

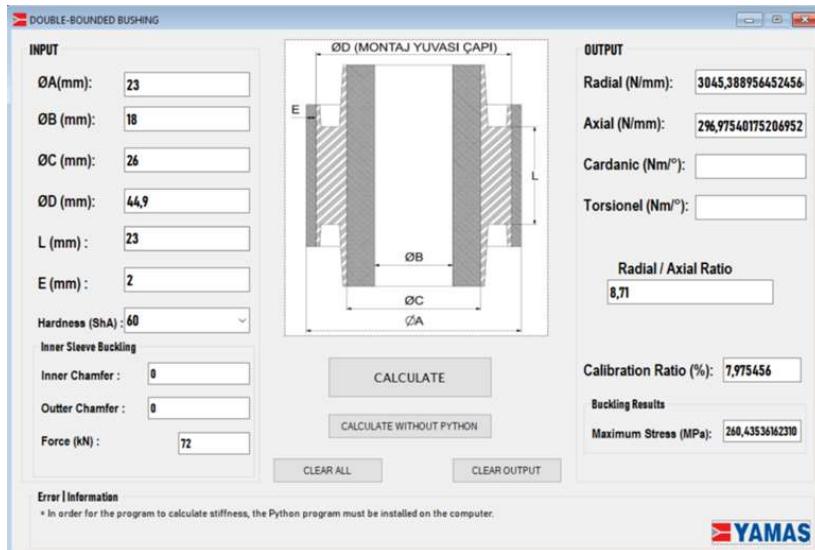
analiz eğrileri karşılaştırılarak statik direngenlik katsayıları ( $K_s$ ) aynı aralıklarda eğrinin doğrusal bölgelerinden hesaplanmıştır.



Şekil 10. Radyal ve eksenel yönde fiziksel test ve analiz sonuçlarının karşılaştırılması

### 3.3. Makine Öğrenme Metodolojisi Sonuçları

Makine öğrenme metodolojisi için oluşturulan program arayüzü ve hesaplamlar, arayüz aracılığıyla girdiler sağlanarak çıktıları elde edecek şekilde tasarlanmıştır. Bu kapsamında sonuçları elde etmeden önce yapılan tüm varyasyonlara ait kuvvet-deplasman eğrilerinin statik direngenlikleri ( $K_s$ ) hesaplanmıştır. Makina öğrenme metodolojisine sonuç olarak tasarım değişkenlerine bağlı her statik direngenlik katsayısı ( $K_s$ ) tek değer olarak entegre edilmiştir. Oluşturulan program için tasarım parametreleri arayüze girilir ve sonuçlar statik direngenlik katsayısı ( $K_s$ ) olarak elde edilir. Tasarım değişkenleri girildikten sonra programın verdiği çıktılar Şekil 11'de görülmektedir.



Şekil 11. Nöral ağ yapısının girdi-çıktı sonuç arayüzü

### 3.4. Sonuçların Karşılaştırılması

Makine öğrenme tabanlı tasarım optimizasyon programı için istenen tasarım değişkenlerine bağlı statik direngenlik sonuçlarının doğruluk oranları yapısal analiz sonuçları ve fiziksel test sonuçları ile ayrı ayrı karşılaştırılmıştır. Her tasarım varyantı için belirlenen tasarım değişkenleri; kauçuk yüksekliği, kauçuk genişliği, kauçuk sertliği ve kalibre oranı olmak üzere bu tasarım değişkenlerine bağlı elde edilen sonuçlar Tablo 3'teki gibi listelenmiştir.

Tablo 3. Yapısal analiz&fiziksel test&makine öğrenim tabanlı program sonuçlarının karşılaştırılması

VARYASYON		TASARIM PARAMETRELERİ-GİRDİLER				SONUÇLAR-ÇIKTILAR	
		KAUÇUK YÜKSEKLİĞİ [mm]	KAUÇUK GENİŞLİĞİ [mm]	KAUÇUK SERTLİĞİ [shA.]	KALİBRE ORANI [%]	RADYAL DİRENGENLİK [N/mm]	EKSİNEL DİRENGENLİK [N/mm]
V1	TEST SONUÇLARI	41,20	9,85	50	5,80	3220,0	355,0
	ANALİZ SONUÇLARI					3381,0	311,5
	MAKİNE ÖĞRENİM SONUÇLARI					3444,2	322,4
V2	TEST SONUÇLARI	19,50	4,75	75	7,60	8450,0	790,0
	ANALİZ SONUÇLARI					8255,0	677,4
	MAKİNE ÖĞRENİM SONUÇLARI					8402,8	703,0
V3	TEST SONUÇLARI	22,40	6,00	65	10,00	10180,0	560,0
	ANALİZ SONUÇLARI					8679,0	455,3
	MAKİNE ÖĞRENİM SONUÇLARI					8813,3	467,8
V4	TEST SONUÇLARI	18,50	7,50	70	6,00	2032,0	305,0
	ANALİZ SONUÇLARI					1986,0	278,3
	MAKİNE ÖĞRENİM SONUÇLARI					2021,5	286,8
V5	TEST SONUÇLARI	16,00	5,25	70	3,60	4924,0	410,0
	ANALİZ SONUÇLARI					4937,0	370,3
	MAKİNE ÖĞRENİM SONUÇLARI					5007,7	382,3
V6	TEST SONUÇLARI	23,00	8,20	50	8,58	2272,0	230,0
	ANALİZ SONUÇLARI					2129,0	246,1
	MAKİNE ÖĞRENİM SONUÇLARI					2170,4	254,9
V7	TEST SONUÇLARI	23,00	8,20	55	8,58	2735,0	275,0
	ANALİZ SONUÇLARI					2802,0	240,5
	MAKİNE ÖĞRENİM SONUÇLARI					2832,2	248,4
V8	TEST SONUÇLARI	23,00	8,20	60	8,58	3114,0	330,0
	ANALİZ SONUÇLARI					3001,0	287,5
	MAKİNE ÖĞRENİM SONUÇLARI					3045,4	297,0

#### 4. TARTIŞMA

Ürün geliştirme süreçlerinde, tasarımın tüm performans gereksinimlerini karşılaması için tasarım-analiz döngüsünün defalarca tekrarlanması gerekmektedir. Parçanın yapısal karmaşıklığı ve kullanılan malzemenin doğrusal olmayan karakteri göz önüne alındığında, bu döngü kimi durumlarda oldukça uzun zamanlara yayılabilmektedir. Bu çalışma kapsamında elde edilen bulgular, titreşim sönümleyici burçlar için geliştirilen makine öğrenimi tabanlı tasarım optimizasyon yaklaşımının, geleneksel doğrulama süreçlerine kıyasla önemli ölçüde zaman tasarrufu sağladığını göstermektedir.

Bu amaçla geliştirilen programda, sinir ağı metodolojisi kullanılarak tahmin yapabilen bir Python tabanlı model oluşturulmuştur. Model, sistem içerisinde entegre edilen veri seti ile eğitilmekte ve kullanıcı tarafından girilen tasarım değişkenlerine bağlı olarak tahmin yürütülmektedir. Program arka planında çalışan Python kodu, makine öğrenimi tabanlı sınırlı ağı algoritmasını çalıştırarak radyal ve eksenel yönlerde statik direngenlik değerlerinin öngörülmesini sağlamaktadır. Elde edilen sonuçlar daha sonra program arayüzünde kullanıcıya sunulmaktadır. Bu yaklaşım sayesinde, klasik tasarım-analiz döngüsünün gerek zaman gereklilik açısından oluşturduğu yük önemli ölçüde azaltılmıştır. Ayrıca, fiziksel testler ve yapısal analizlerle karşılaştırılan tahmin sonuçlarının yüksek doğruluk seviyeleri, yöntemin mühendislik uygulamalarında kullanılabilirliğini göstermektedir.

Çalışma kapsamında fiziksel test verileri ile sonlu elemanlar analizinden elde edilen sonuçlar arasındaki uyum oranı ortalama **%92** olarak hesaplanmıştır. Makine öğrenimi modelinin fiziksel test verilerine göre doğruluk oranı ise **%94** seviyesinde bulunmuştur. Hiperelastik malzemelerin karmaşık mekanik davranışları dikkate alındığında bu doğruluk seviyeleri mühendislik açısından tatmin edici kabul edilmektedir. Sonuç olarak elde edilen veriler, makine öğrenimi temelli bu metodolojinin konvansiyonel titreşim sönümleyici burçların

tasarım ve doğrulama süreçlerinde etkin bir şekilde kullanılabileceğini ortaya koymaktadır. Ayrıca, modele sağlanan veri setinin genişletilmesiyle tahmin doğruluğunun gelecekte daha da artırılması hedeflenmektedir.

## KAYNAKLAR

- [1] Töpel E, Fuchs A, Büttner K, Kaliske M, Prokop G. (2024) ‘’Machine-Learning-Based Design Optimization of Chassis Bushings.’’ Vehicles. 2024; 6(1):1-21
- [2] Aydoğdu, B. (2023). ‘’Yapıların mekanik davranışının yapay sinir ağları ile modellenmesi ve optimizasyonu.’’ Yayınlanmamış yüksek lisans tezi. Bursa Uludağ Üniversitesi Fen Bilimleri Enstitüsü.
- [3] Kaya, N., "Shape Optimization of Rubber Bushing Using Differential Evolution Algorithm", Hindawi Publishing Corporation Scientific World Journal Volume, Article ID 379196, 2014.
- [4] Gent, A.N. and Yeoh, O.H. (2006) Rubber Chem. Technol., 79(4), 674–676.
- [5] Rivlin, R.S. (1992) Rubber Chem. Technol., 65(2), 51–66.
- [6] Kim, W.D., Lee, H.J. and Kim J.Y. (2004) Int. J. Fatigue, 26(5), 553–560.
- [7] Garcia, R.M.J., Ruiz, S.O.E., Lopez, C., Gonzalez, L.Y.S., Botero, M.G., Betancur, M. 2005. Hyperelastic Material Modeling-Technical Report. Laboratorio CAD/CAM/CAE Departamento De Ingenieria Macanica Universidad EIFAT. Medellin.
- [8] Sayyaadi H, Shokouhi N. (2009) ‘’A new model in rail–vehicles dynamics considering nonlinear suspension components behavior.’’ International Journal of Mechanical Sciences. 51,3, pp.222-232.
- [9] Wang MJ. (1998) ‘’Effect of polymer–filler and filler–filler interactions on dynamic properties of filled vulcanizates’’, Rubber Chemistry and Technology, Vol.71, pp.520-589. Vuchic, V.R. (2007), Urban Transit Systems and Technology, John Wiley & Sons, Hoboken, NJ, 624 pages.
- [10] Mullins L., Tobin N. R. (1969) ‘’Softening of Rubber by Deformation’’, Rubber Chemistry and Technology, Vol.42, No.1, pp.339-362
- [11] Dean G, Duncan J, Johnson A. (1984) ‘’Determination of non-linear dynamic properties of carbon-filled rubbers.’’ Polymer testing. 4,2, pp.225-249.